Processamento de dados massivos com Spark: conceitos, desafios e programação

Vinícius Dias
viniciusvdias@ufop.edu.br

DECSI
DEPARTAMENTO DE COMPUTAÇÃO E SISTEMAS

UFOP
Universidade Federal de Ouro Preto

Vivemos em um mundo de dados...

De que volume de dados estamos falando?

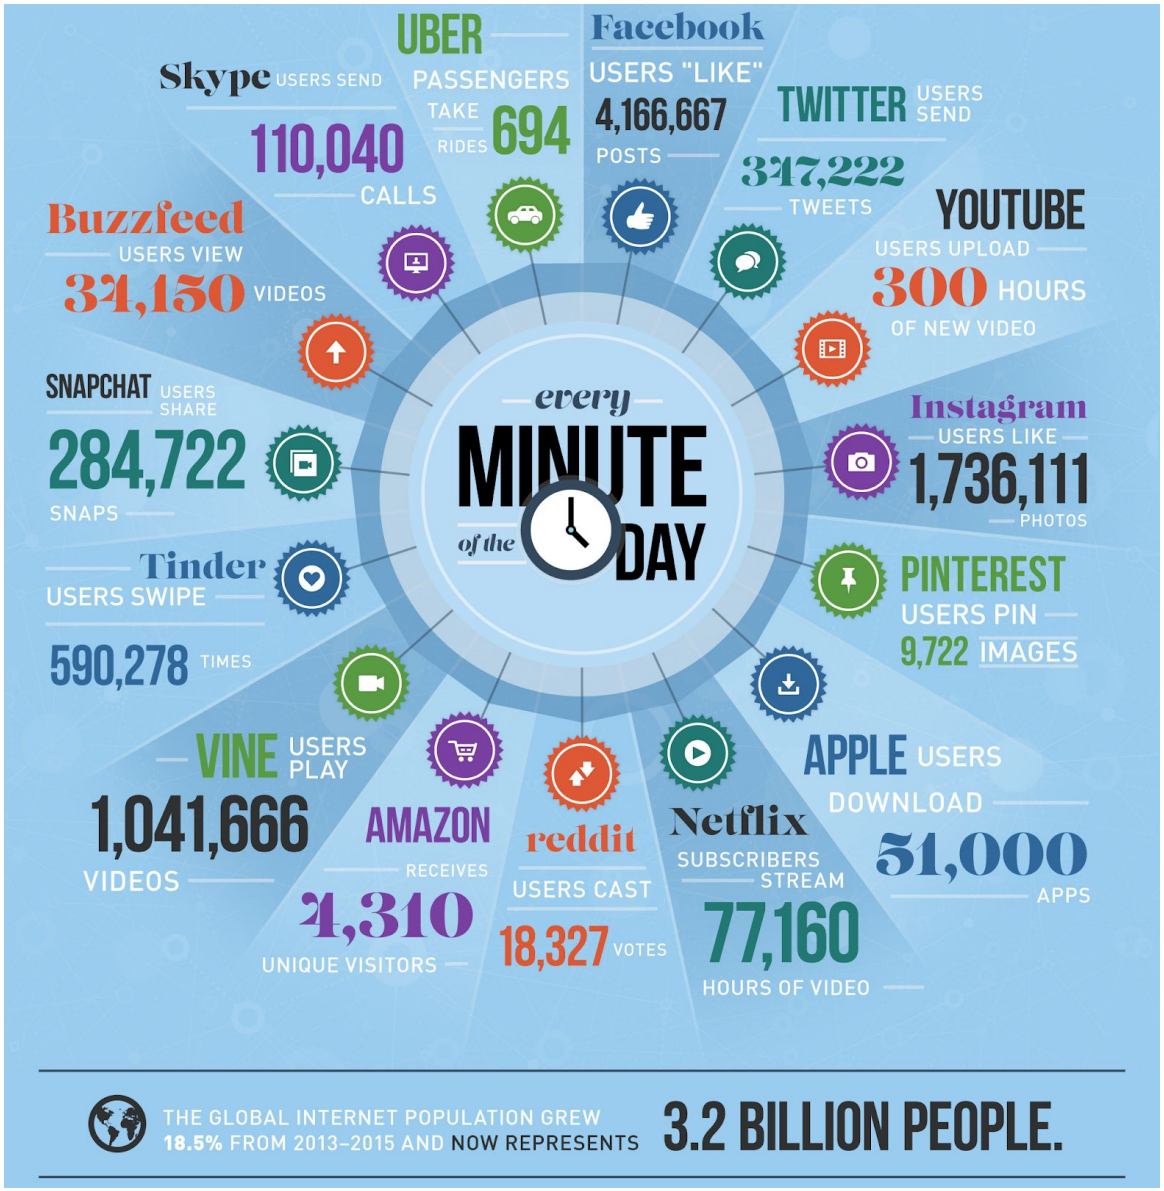

Domo Data Never Sleeps 3.0

Mas não só "volume"
3 V's de Big-Data

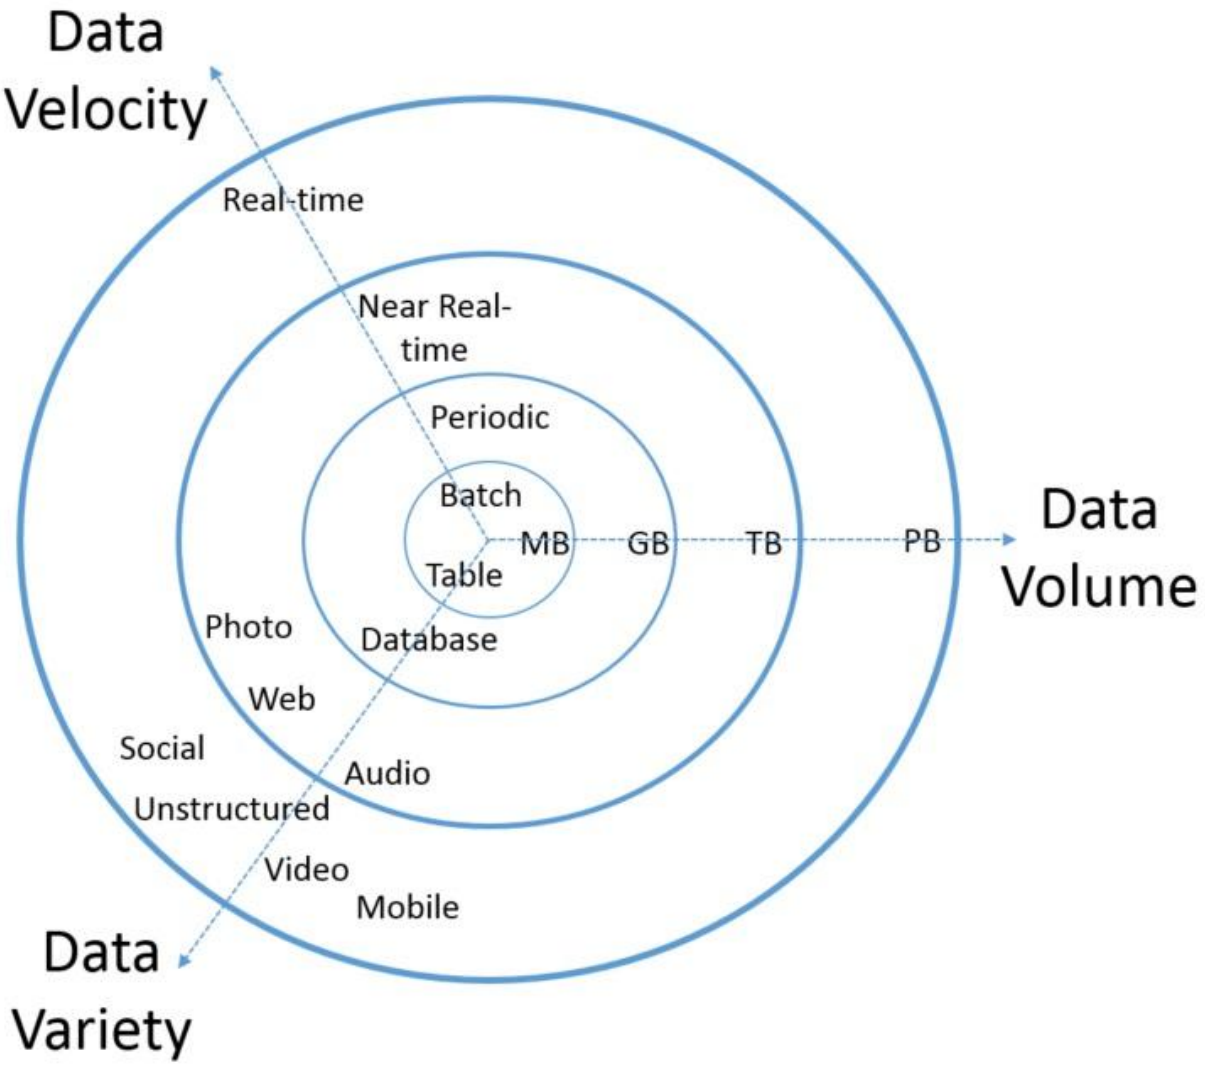

"Big Data, real world", Linguamatics

Mas não só "volume"

4 V's de Big-Data

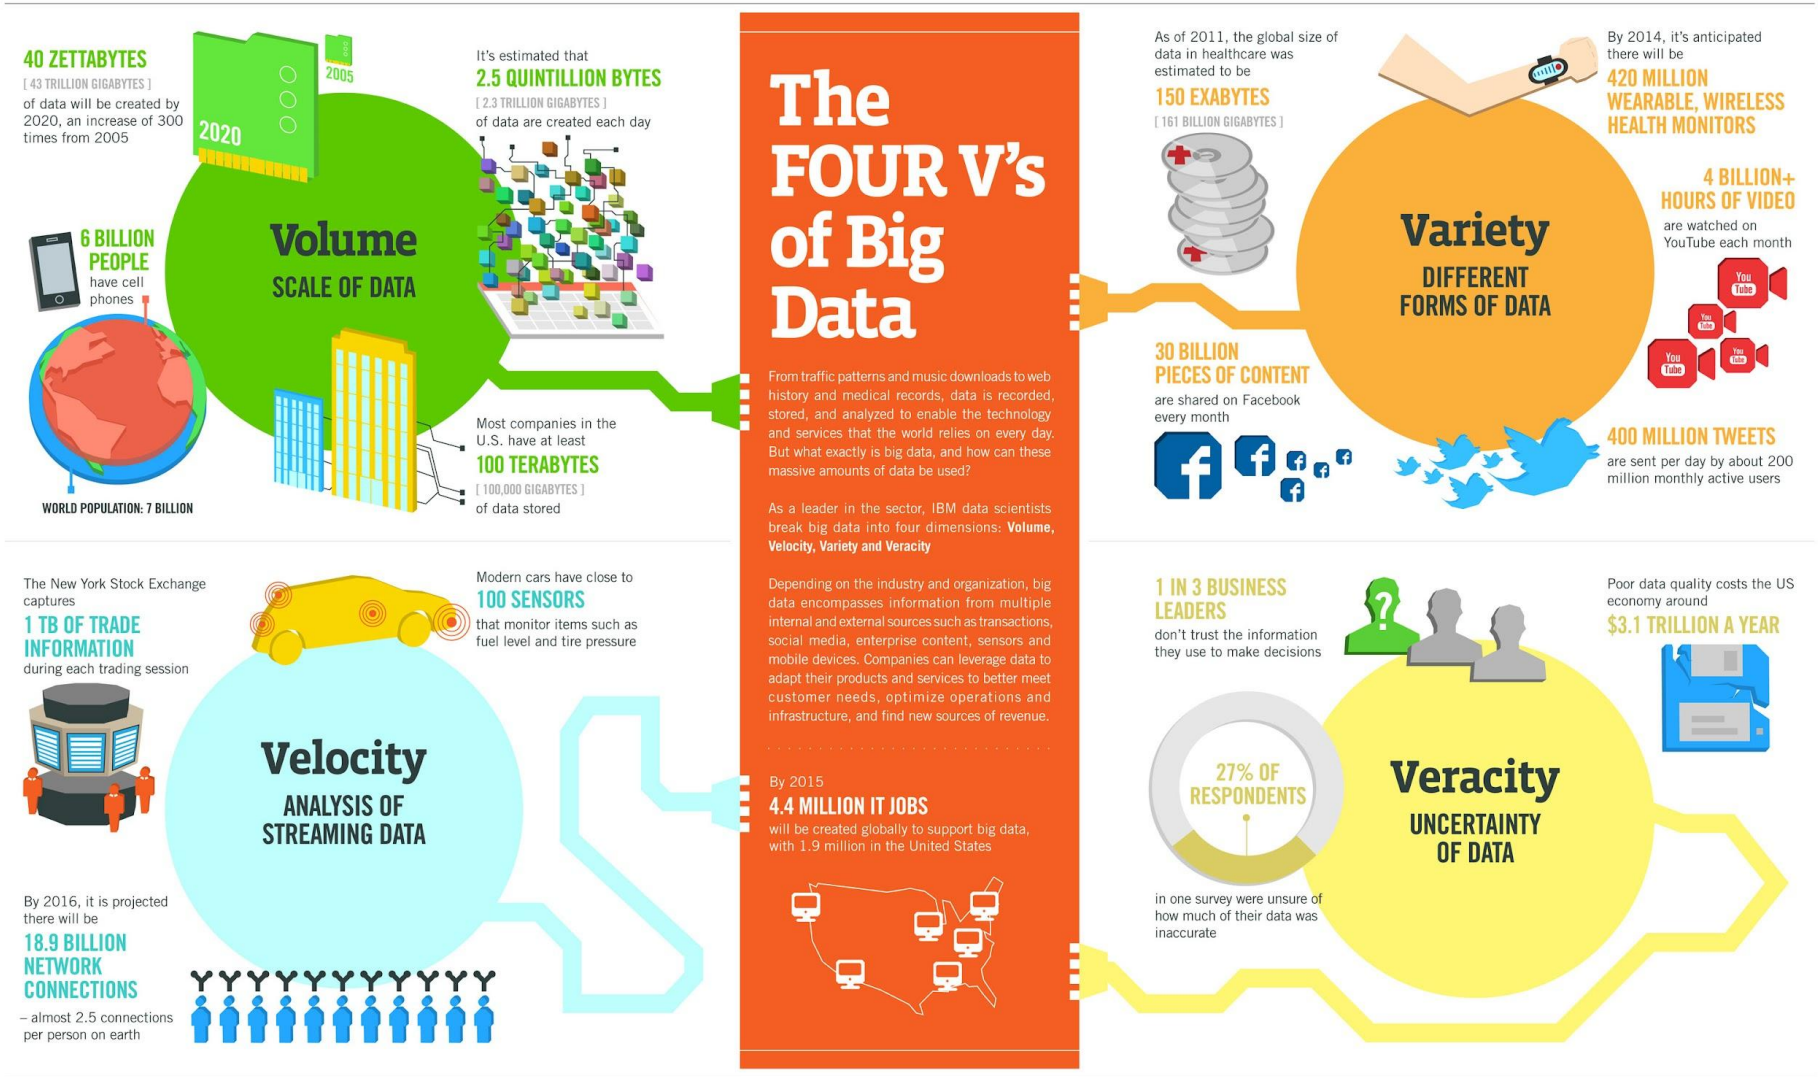

Um consenso

"*Big Data* é qualquer dado que é caro para se gerenciar e do qual é difícil extrair valor"

Thomas Siebel, Diretor do AMPlab, Universidade de Berkeley

Arquiteturas tradicionais têm seus limites

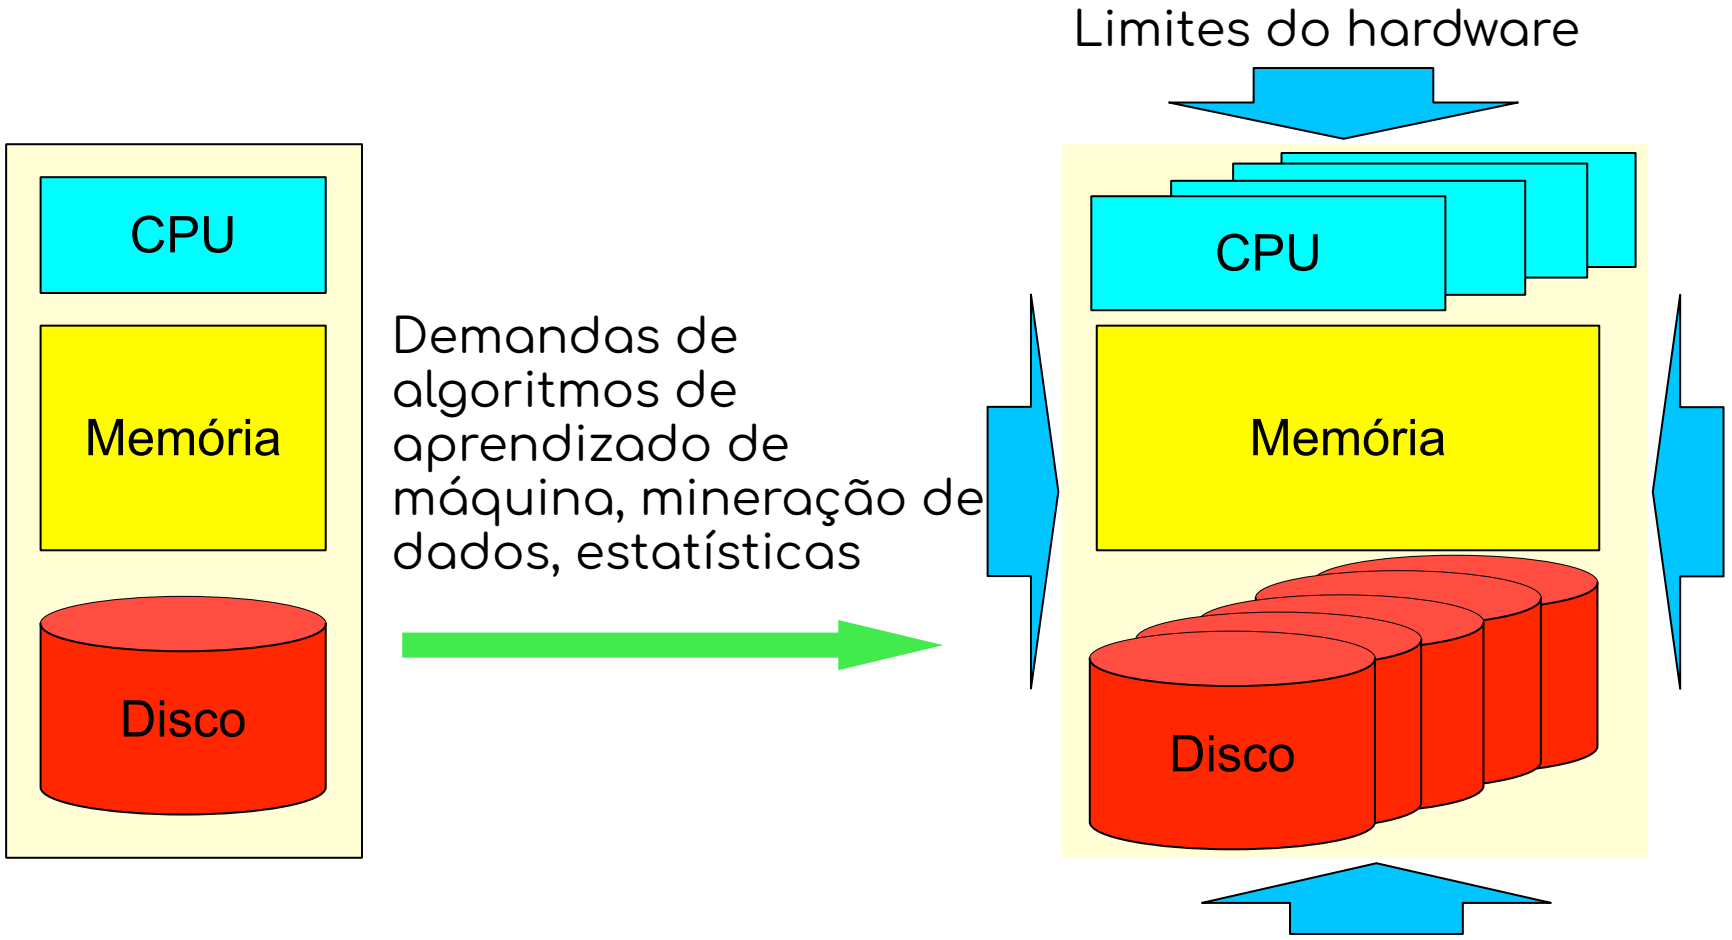

Grandes ideias

⇒ Crescer (scale) "out", não "up"

- Múltiplas máquinas em um cluster/datacenter
- Solução barata

⇒ Mover o processamento para os dados

- A conexão entre máquinas tem banda limitada

⇒ Processar os dados sequencialmente, se possível

- "*Seeks*" são caros, mas a taxa de transferência é OK

Solução: agregados de computadores

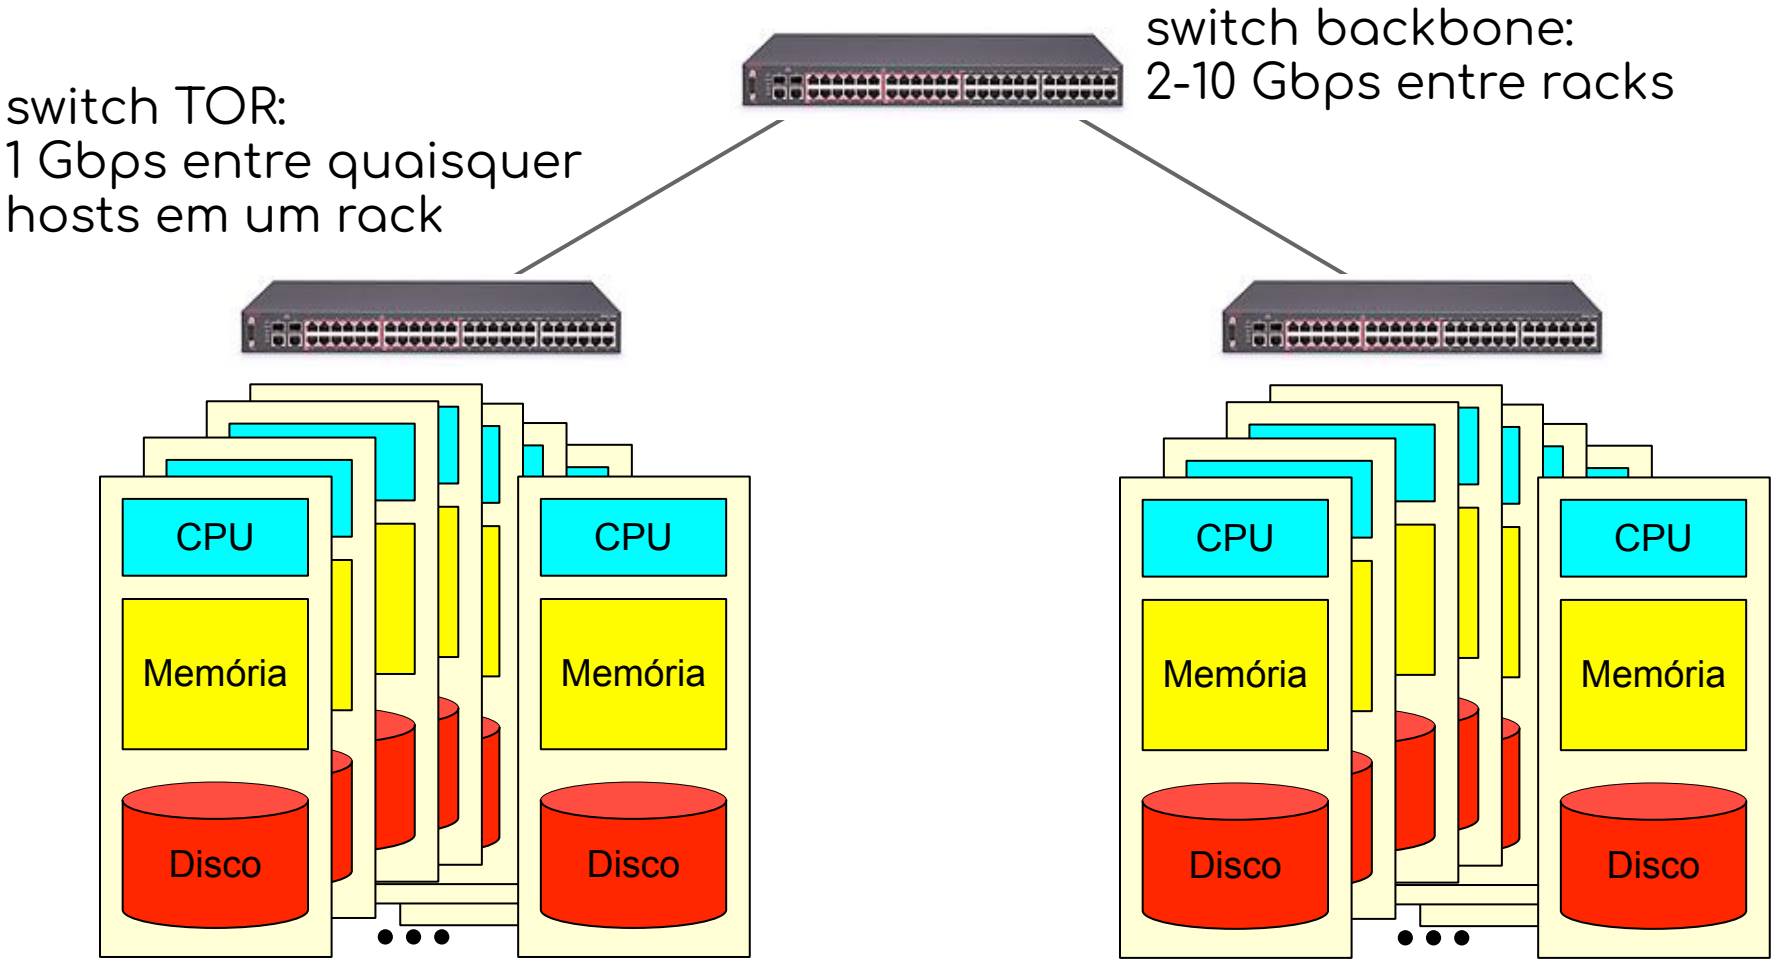

cada rack contém de 16 a 64 nós

“O datacenter é o computador”

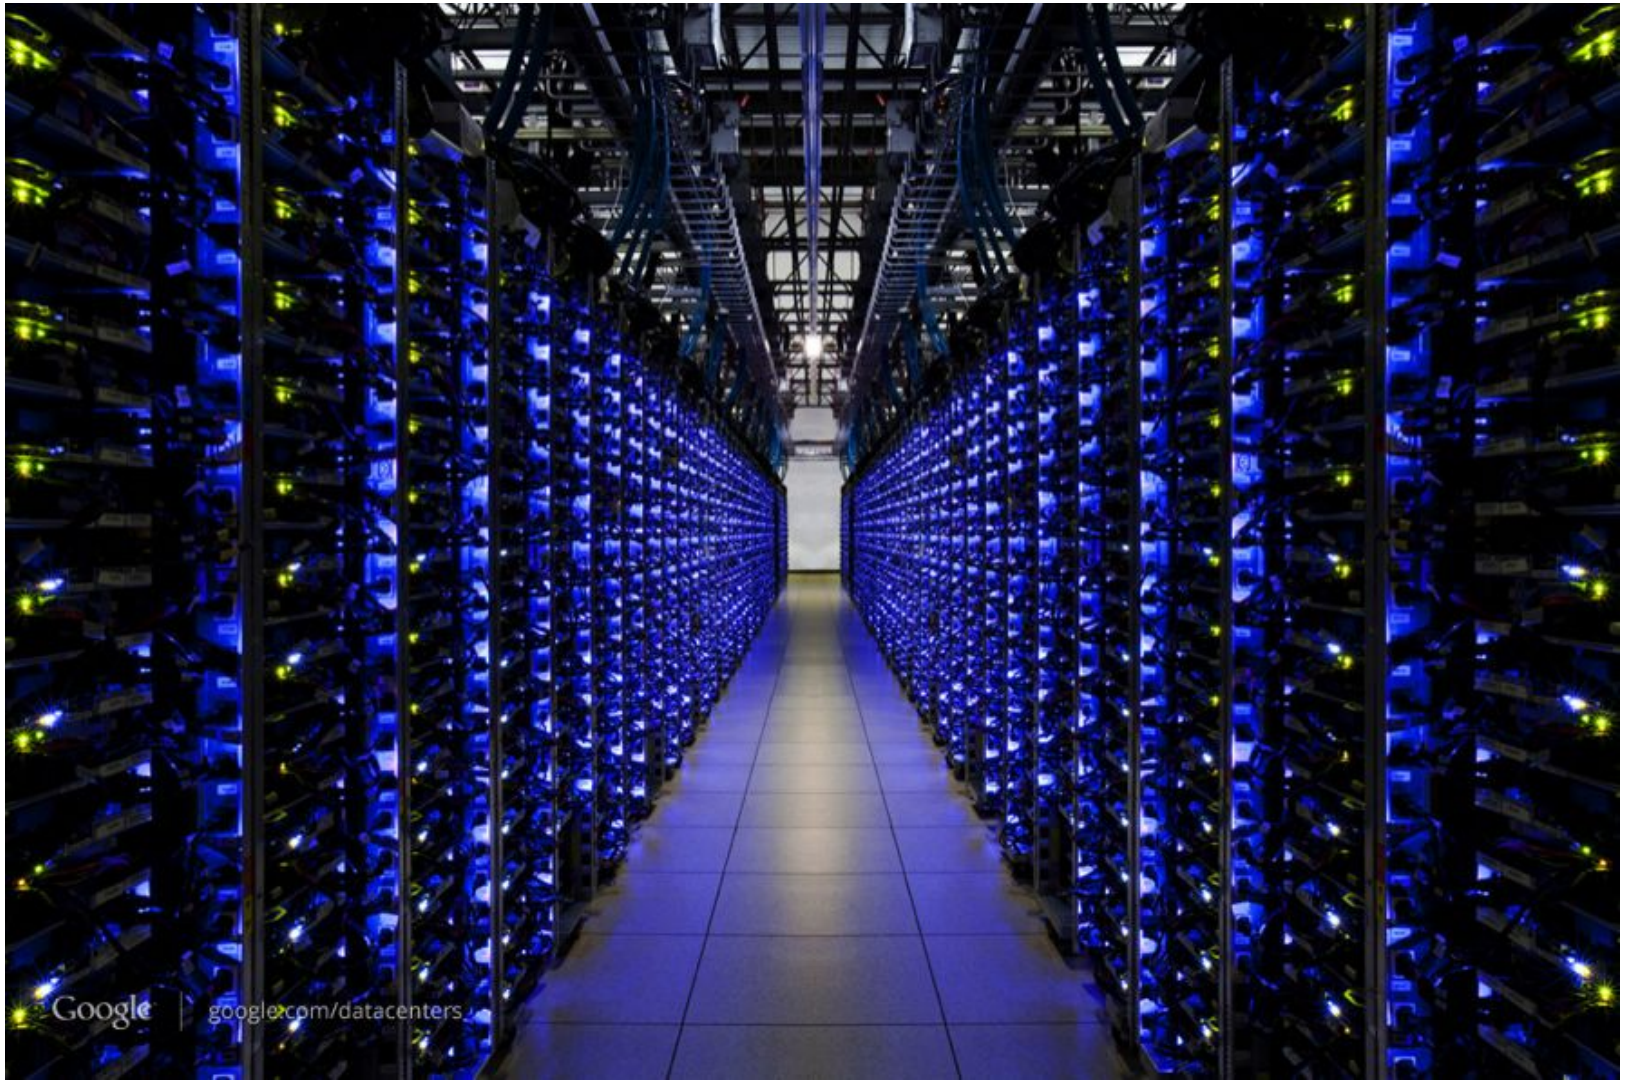

Roteiro

1. Motivação e contextualização
2. **Spark: uma solução genérica e integrada**
3. SparkSQL: lidando com dados estruturados
4. SparkStreaming: processamento contínuo

O modelo Map-Reduce

(Google, OSDI 2004)

Dividir para conquistar!

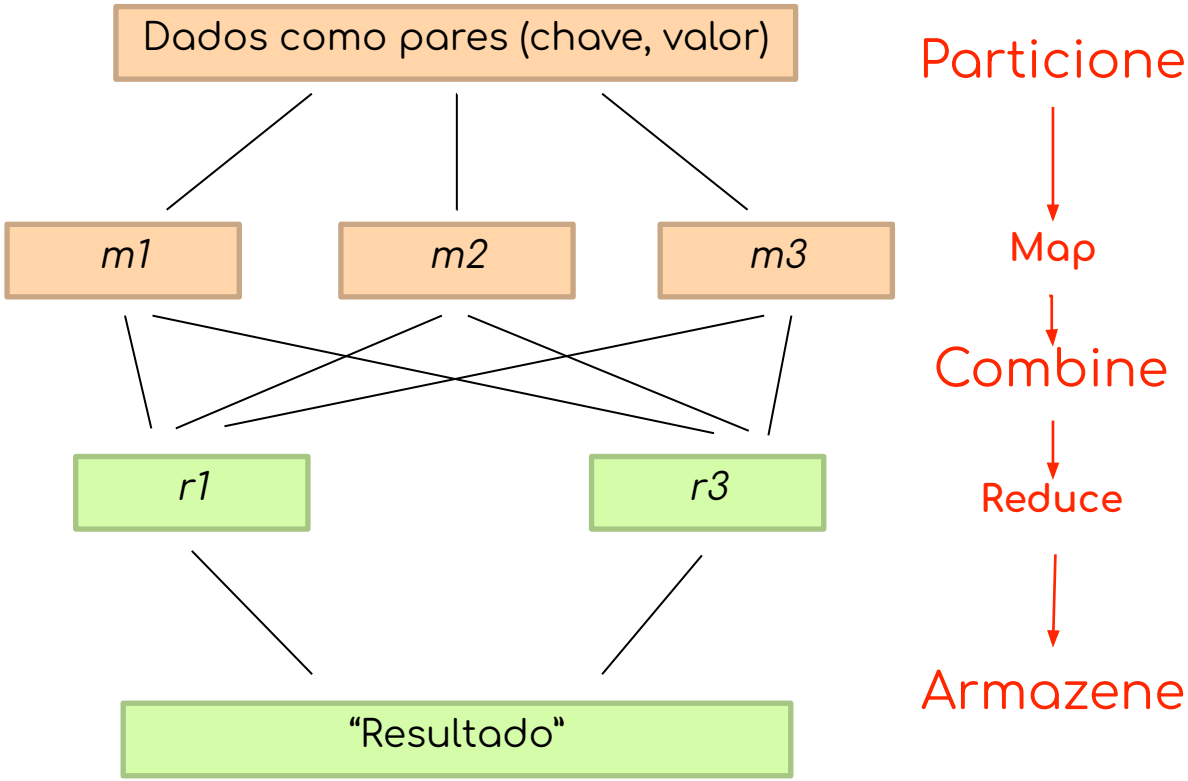

Conta palavras com MapReduce

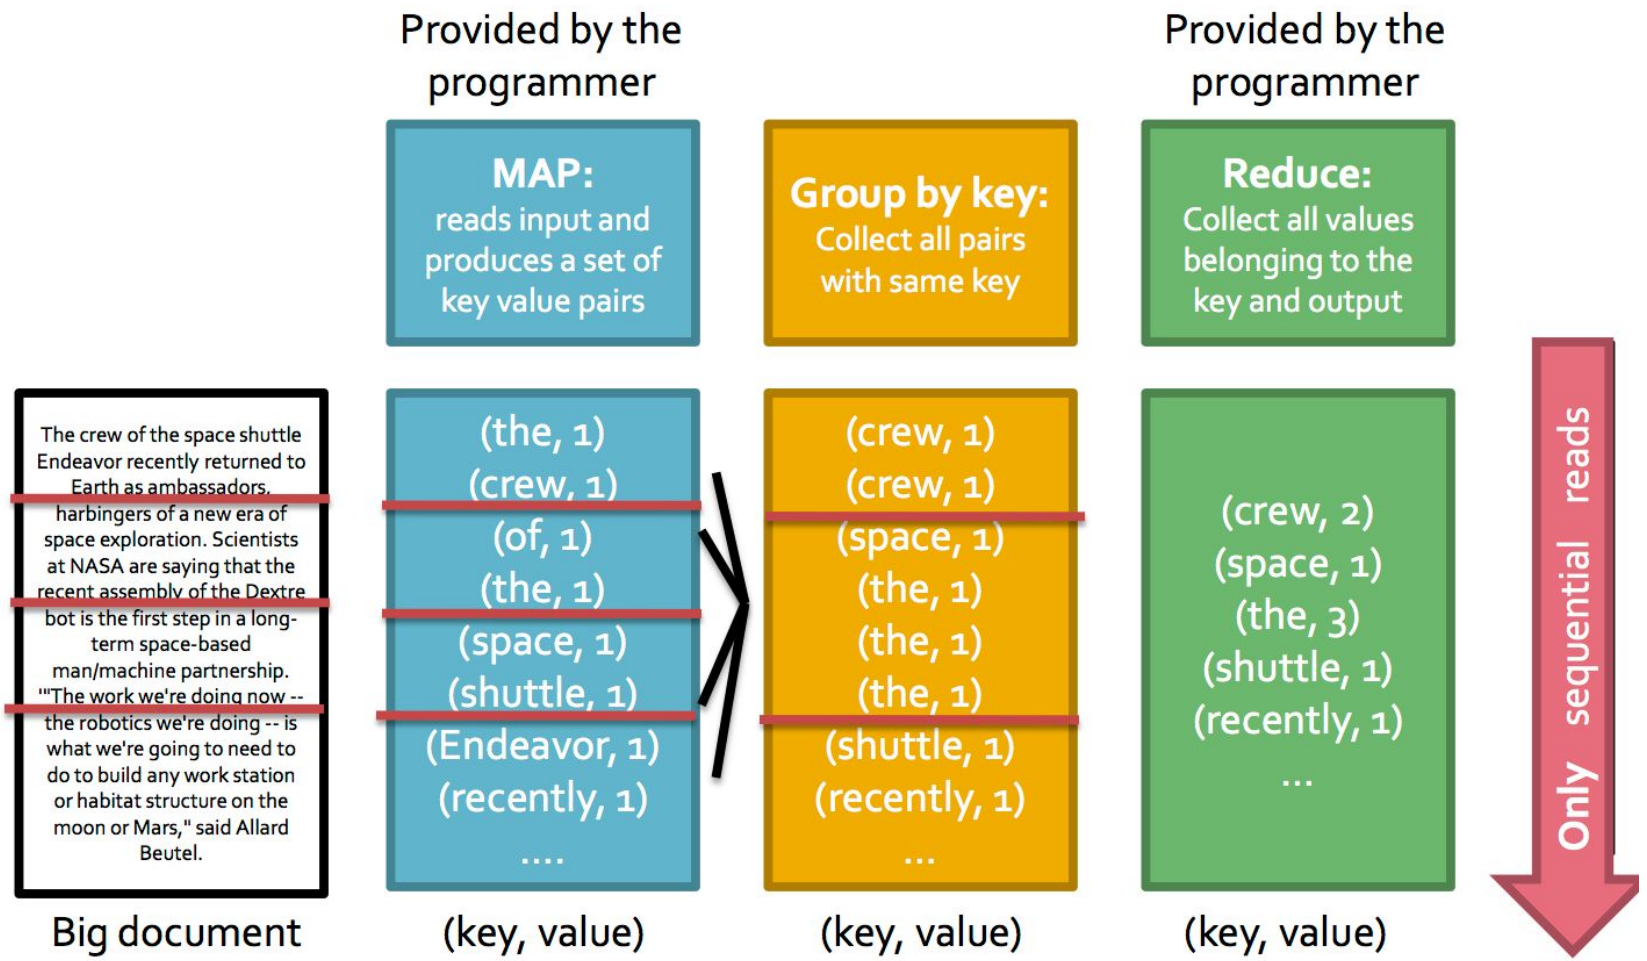


May 2013
NACS
The Association for Convenience & Fuel Retailing
PLUS:
Maverik's New Debit Card
Candy's Sweet Spot
BIG DATA
Harvard Business Review
GETTING CONTROL OF BIG DATA
The Economist
Obama the warrior
Misgoverning Argentina
The economic shift from West to East
Genetically modified crops blossom
The right to eat cats and dogs
The data deluge
AND HOW TO HANDLE IT: A 14-PAGE SPECIAL REPORT
Biomedical Computation REVIEW
Big Data Analytics in Biomedical Research
PLUS:
Privacy and Biomedical Research: Building a Trust Infrastructure
COMMUNICATIONS OF THE ACM
nature
THE BITER BIT
Viral infections for viruses
TROPICAL CYCLONES
The strong get stronger
SCIENCE IN THE PETABYTE ERA
openSUSE 12.2
HADOOP BIG DATA ON A BUDGET
LINUX MAGAZINE
GET LUCKY
4 Fine tools for prettier presentations
PMKT21
Desvendando a Era do Big Data
O perigo das licitações indecorosas
Inovação é a palavra-chave para empresas dispostas a crescer
hadoop
veja
ENTENDA O QUE É BIG DATA
O MEGAFENÔMENO DIGITAL QUE TRANSFORMA EM RIQUEZA DADOS PESSOAIS, POSTS, TUÍTES, E-MAILS E ATÉ CLIQUES
FOREIGN AFFAIRS
The Rise of Big Data
Kenneth Cukier & Viktor Mayer-Schoenberger
Government Executive
BIG DATA
HOW IT'S MAKING AGENCIES SMARTER

M-R não resolve todos os problemas

⇒Processamento de consultas

- Às vezes, tudo que se precisa é uma consulta SQL

⇒Processamento iterativo

- Algoritmos que não se resumem a um único M-R

⇒Processamento de *streams*

- Nem sempre o arquivo é a forma da entrada

⇒Processamento de grafos (redes complexas)

- Estruturas irregulares que afetam o fluxo dos dados e do processamento

Spark: uma solução integrada

⇒ Plataforma de computação em *clusters.*
- criada para ser rápida e de propósito geral.

⇒ O processamento é multiestágio:
- Representado como grafo direcionado e acíclico (DAG).
- Não apenas um par Map/Reduce
- Processamento em memória (diferente do Hadoop).

⇒ Toda a computação acontece em função de estruturas de dados denominadas RDDs (*Resilient Distributed Dataset*)

Popularidade do Spark

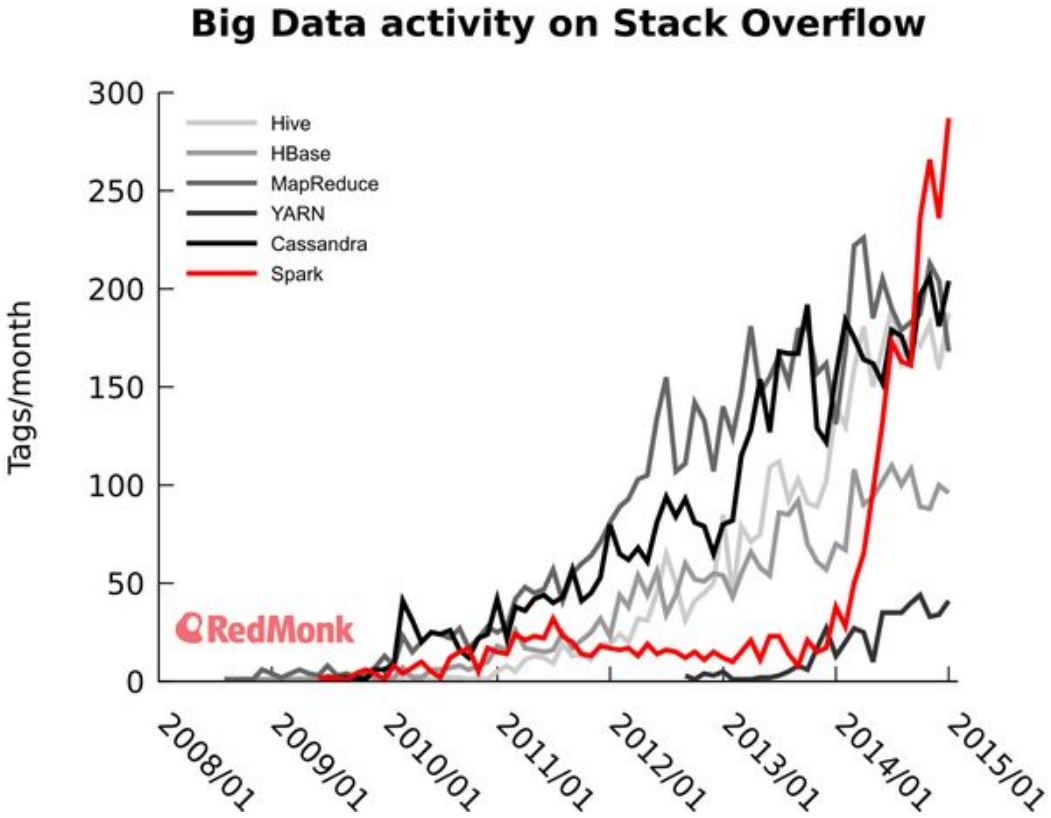

fonte: Donnie Berkholz, RedMonk

Reconhecimento da academia

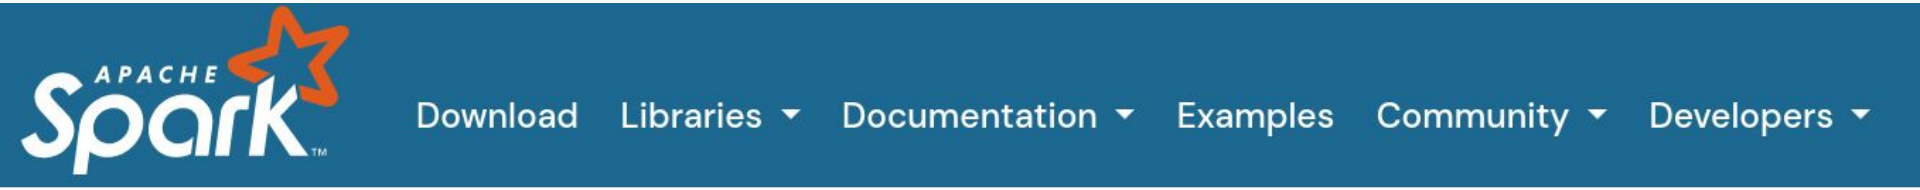

SIGMOD Systems Award for Apache Spark

Apache Spark received the SIGMOD Systems Award this year, given by SIGMOD (the ACM's data management research organization) to impactful real-world and research systems:

> The 2022 ACM SIGMOD Systems Award goes to "Apache Spark", an innovative, widely-used, open-source, unified data processing system encompassing relational, streaming, and machine-learning workloads.

This is a significant achievement by the whole community in Apache Spark that the whole community earned together.

fonte: apache.spark.org

Arquitetura

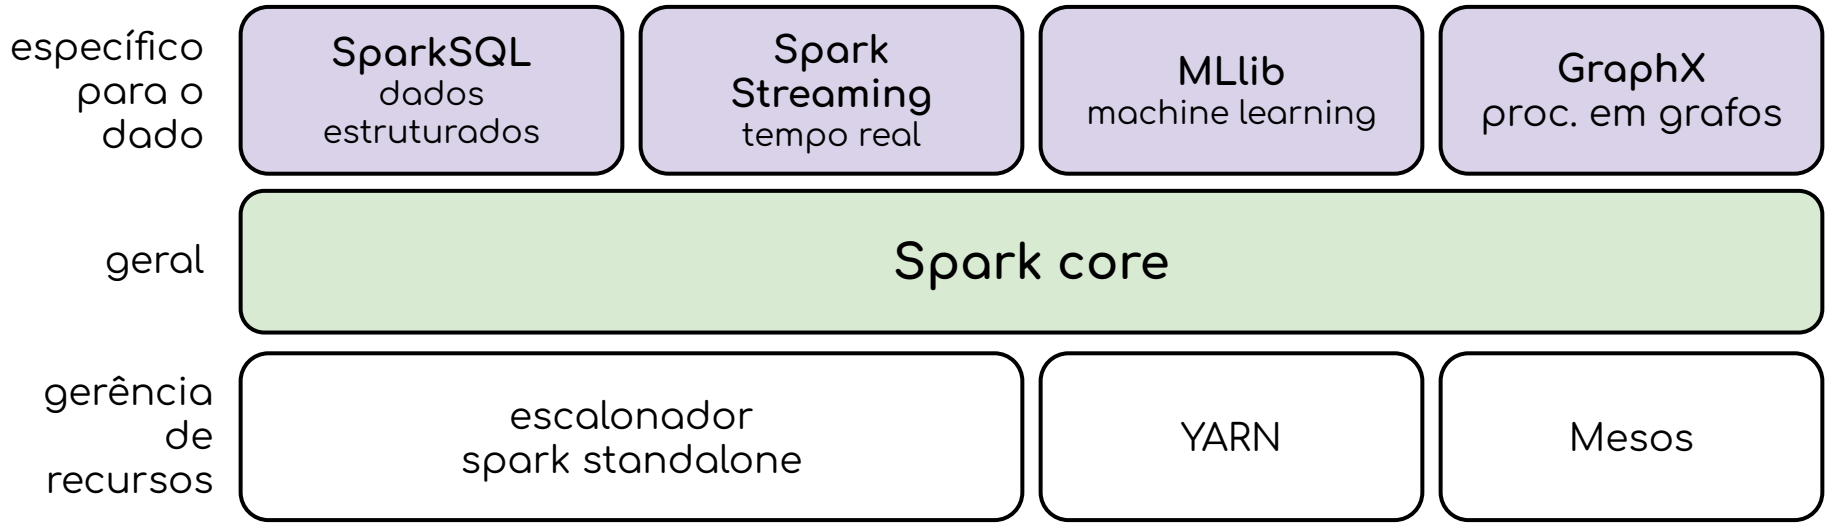

⇒ **geral:** processamento em DAGs, com chave/valor e/ou particionamento.

⇒ **específico para o dado:** conhecimento sobre a estrutura do dado possibilita especializar o *Spark core* e ganhar em desempenho.

⇒ **gerência de recursos:** é preciso orquestrar a concessão de recursos físicos das máquinas do *cluster* (memória, CPU-cores e disco).

Implementação e API's

⇒ Spark é implementado em Scala:

- executa sobre a JVM
- funcional + orientada a objetos
- também permite programação procedimental

⇒ Linguagens com API para Spark:

- Scala (nativo)
- Python
- Java
- R (DataFrames/SparkSQL, principalmente)

Utilizaremos a API de Scala para os exemplos, principalmente.

Ferramentas de trabalho

Investigação interativa: spark shell

Desenvolvimento de aplicação: spark submit

Exemplo: selecionando itens

Quantas linhas contêm a palavra Python?

```
$ ./bin/spark-shell
…
scala> val lines =
         sc.textFile("file:///home/pdm/README.md")
lines: org.apache.spark.rdd.RDD[String] = ...

scala> val pythonLines =
                lines.filter(line => line.contains("Python"))
pythonLines: org.apache.spark.rdd.RDD[String] = ...

scala> pythonLines.first()
res1: String = high-level APIs in Scala, Java, and Python, and ...
```

Conceitos básicos

⇒ Uma aplicação consiste de um programa chamado *driver*.

- o *driver* dispara trabalho (local ou no *cluster*).
- o *driver* toma controle do **recurso do cluster** através de um objeto de contexto (*SparkContext*).
- o *driver* descreve o fluxo (DAG) de uma aplicação, composto por coleções de dados distribuídas (RDDs) e seus relacionamentos (operações).
- no modo interativo, o *driver* é o próprio *shell* em execução.

SparkContext

⇒ É a interface entre o *driver* e recursos.

⇒ *spark-shell:* o contexto é automaticamente instanciado como ‘`sc`’:

```
scala> sc
res0:org.apache.spark.SparkContext=...
```

⇒ *spark-submit:* o contexto precisa ser instanciado manualmente:

```
object MySparkDriver {
    def main(args: Array[String]) {
        val sc = new SparkContext (conf)
        …
        sc.stop()
    }
}
```

Conceitos básicos

(execução em *cluster*)

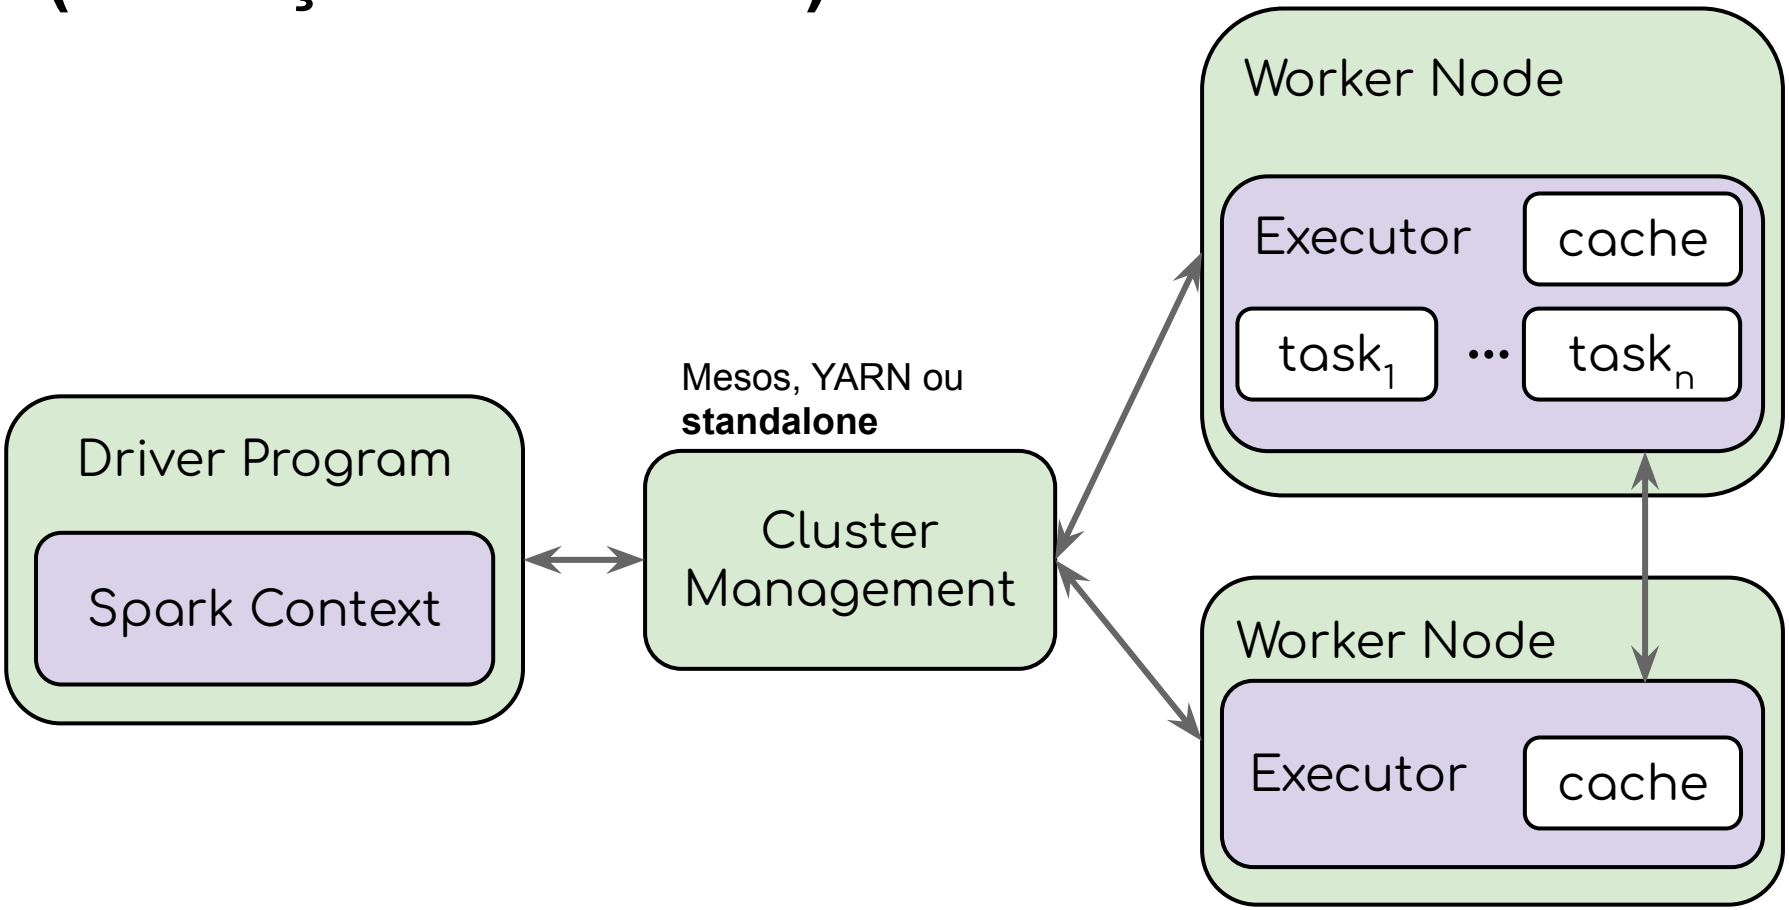

Os *executors*

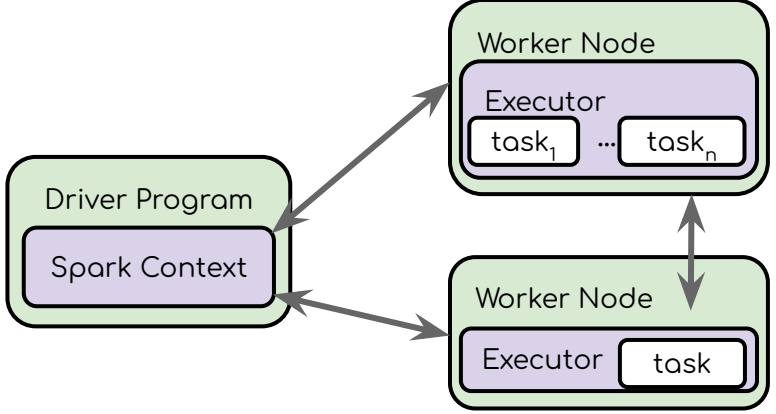

⇒ Realizam computação paralela para o *driver.*
- seu tempo de vida está associado a uma aplicação.

⇒ A computação paralela é no nível de tarefas.
- tarefas computam pedaços de uma coleção.
- é OK associar uma tarefa a um core virtual.

⇒ A memória do *executor* é particionada em:
- área de *caching:* dados em memória.
- área necessária para executar tarefas.

⇒ Na execução do tipo local existe apenas um executor acoplado ao driver (*default*).

Comandos

spark-submit **ou** spark-shell

```
$ ./bin/spark-submit \
    --class <classe_da_aplicação> \
    --master <url_do_master> \
    --executor-memory <mem_por_executor> \
    --executor-cores <num_vcores> \
    <jar_da_aplicação> \
    <parâmetros_da_aplicação>
```

```
$ ./bin/spark-shell \
    --master <url_do_master> \
    --executor-memory <mem_por_executor> \
    --executor-cores <num_vcores> \
```

Execução de aplicações (URLs)

URL em *--master URL*	**descrição**
local	**sem paralelismo**
local[K]	**K *worker threads***
local[*]	uma *worker thread* por *vcore*
local-cluster[E,C,M]	E executors, C cores cada, M MB de memória
spark://host:port	standalone (port padrão é 7077)
mesos://host:port	sobre o mesos
yarn-client	sobre o yarn (apenas executors)
yarn-cluster	sobre o yarn (inclusive driver)

Modelo de programação

A aplicação é uma DAG de coleções e operações

1. Leia uma base de dados (resultado: C_0).
2. Formate C_0 (resultado: C_1).
3. Leia outra base de dados (resultado: C_2).
4. Faça uma junção das bases C_1 e C_2 (resultado: C_3).
5. Então, filtre o C_3 (resultado: C_4) e escreva no disco.

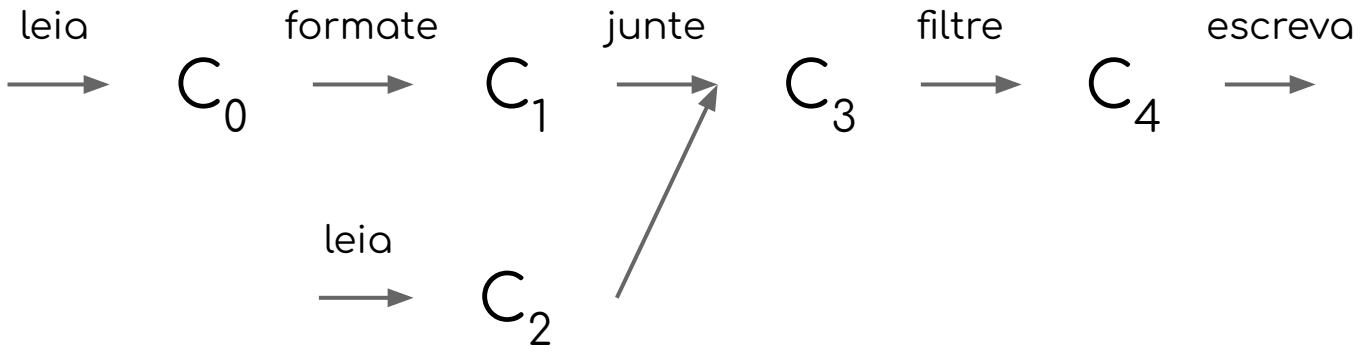

Coleção de dados em Spark

RDD: *Resilient Distributed Dataset*

⇒ RDD é:

- Uma abstração para trabalhar com grandes conjuntos de dados (dataset)
- Um tipo de dados que pode ser manipulado pela API Spark nas diversas linguagens

Conceitos básicos

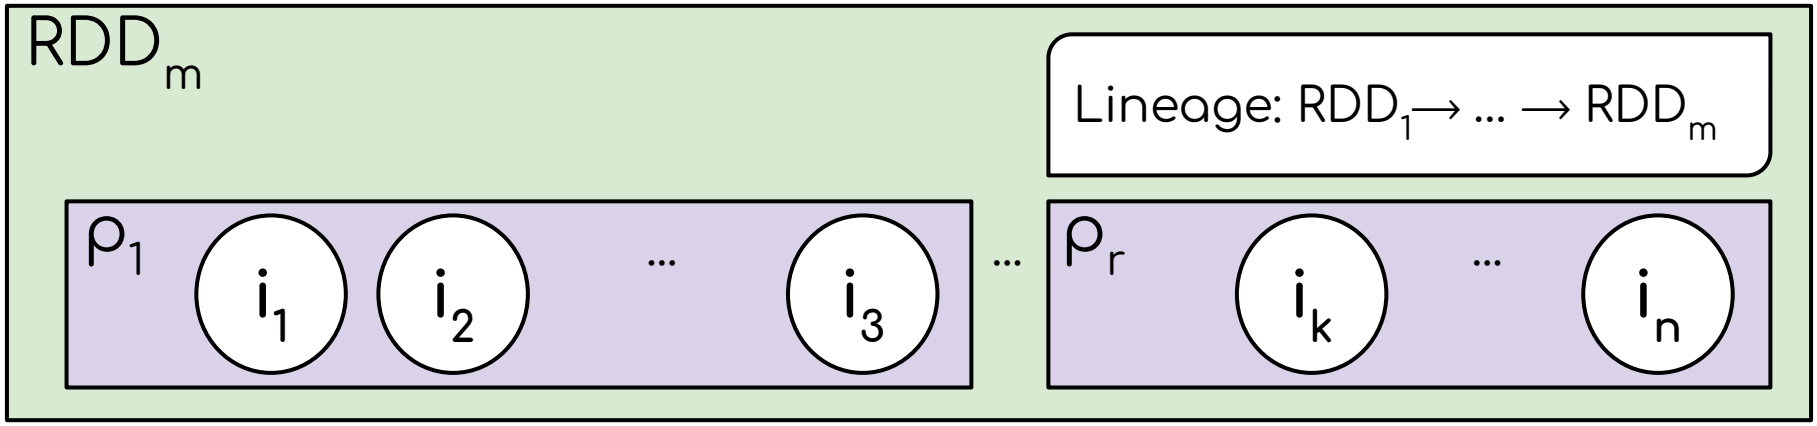

⇒ Imutável

⇒ Tolerante a falhas

⇒ Partição: unidade de persistência e computação.

⇒ Persistência (memória, disco, serializado, etc.).

⇒ O RDD deste exemplo tem:

- **n** itens, **r** partições e dependência de profundidade **m**.

Criação de RDDs: arquivos

⇒ Essa alternativa já foi vista:

```
val linesRDD =
            sc.textFile(“file:///caminho/para/README.md”)
```

⇒ Neste exemplo, a fonte de dados externa é um arquivo.

- o prefixo **file://** indica o sistema de arquivos local.
- **hdfs://** é outra opção comum, se o arquivo estiver no sistema de arquivos do Hadoop (HDFS).

Criação de RDDs: paralelizar

⇒ O *SparkContext* **sc** é capaz de paralelizar/distribuir coleções locais ao programa *driver.*

```
// ...
// essa coleção é local, sem Spark por aqui.
val bigRange = (1 to 1000000)

// aqui existe Spark (RDD)
val bigRangeRDD = sc.parallelize (bigRange)
// ...
```

Operações

⇒ Qualquer operação sobre um RDD se enquadra em uma das categorias:

- Transformação.
  - ➢ criam um novo RDD a partir de outro.
  - ➢ avaliação é preguiçosa (lazy).

- Ação.
  - ➢ retornam resultado para o *driver.*
  - ➢ avaliação é imediata.

Esclarecimentos e exemplo

⇒ Transformação já vista: `filter`.

⇒ Ações já vistas: `count` e `first`.

```
val linesRDD = sc.textFile(“file:///caminho/para/README.md”)
    // criação
    // sem computação, apenas o lineage do RDD foi registrado.

val xlinesRDD = linesRDD.filter(line => line.contains("x"))
    // transformação
    // sem computação, apenas o lineage do RDD foi registrado.

val nxLines = xlinesRDD.count()
    // ação
    // ocorre o disparo de uma computação
    // em especial, do xlinesRDD
```

Mais operações

⇒ map(f) - transformação
- Aplica a função f() a cada elemento x do RDD, gerando um RDD contendo os valores de f(x)

⇒ reduce(f) - ação
- Aplica a função `f()` a todos os elementos do RDD "de uma vez".
- Por exemplo, `(_ + _)` significa "some todos os elem"
- A função tem que ser associativa.

Atenção: estes **não são** os mesmos do Map-Reduce/Hadoop

Avaliação preguiçosa

```
1.  val exRDD = sc.parallelize (1 to 10)
2.  val incExRDD = exRDD.map (n => n+1)
    // ação reduce dispara a computação
3.  val sum = incExRDD.reduce (_ + _)
4.  println (“soma = ” + sum)
```

Atenção: estes **não são** os mesmos Map/Reduce de hadoop

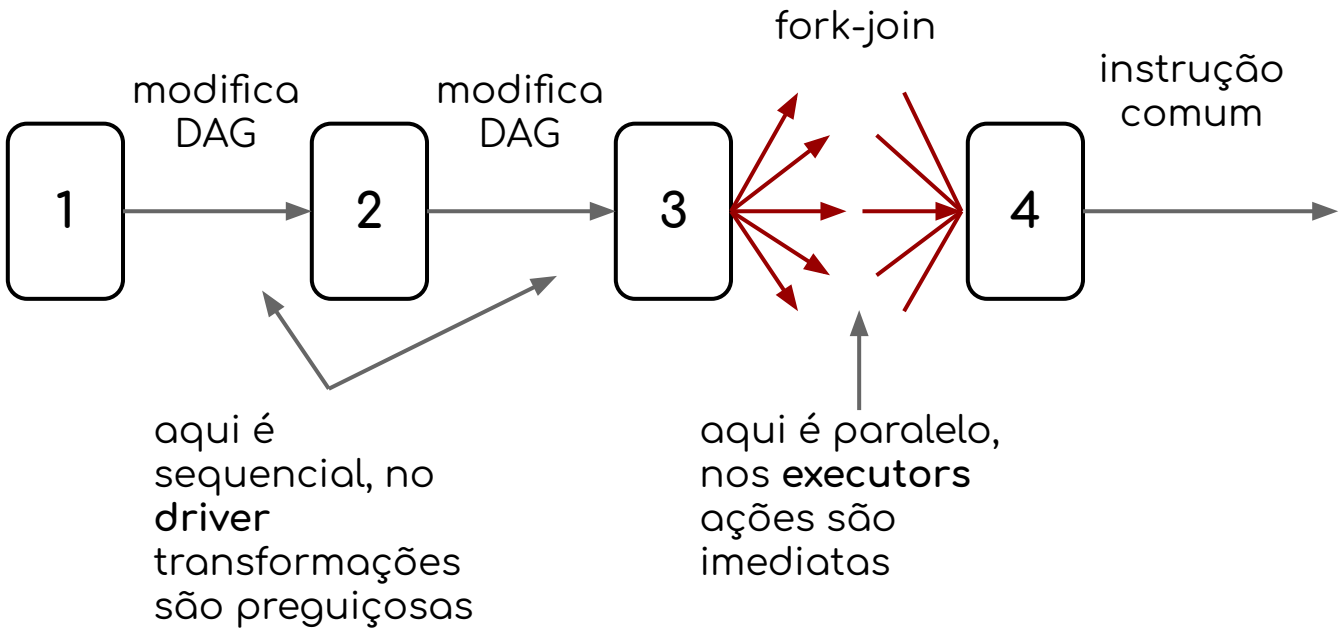

Mais operações

transformações: `flatMap` e `ReduceByKey`

ação: `take`

⇒ `rdd.flatMap(func)`: mapeamento um-para-muitos

- `func`: função que recebe um elemento e mapeia para vários, potencialmente.

⇒ `pairRdd.reduceByKey(func)`: combina todos os valores de mesma chave.

- `func`: recebe dois valores e retorna um terceiro valor representando a combinação dos dois primeiros.

⇒ `rdd.take(n)`: coleta n itens do `rdd` para o *driver*.

WordCount em Spark

```
val lines = sc.textFile (inputFile)
    // cada item do RDD é uma linha do arquivo (String)
```

WordCount em Spark

```
val lines = sc.textFile (inputFile)
    // cada item do RDD é uma linha do arquivo (String)
val words = lines.flatMap (line => line.split (" "))
    // cada item do RDD é uma palavra do arquivo
```

WordCount em Spark

```
val lines = sc.textFile (inputFile)
    // cada item do RDD é uma linha do arquivo (String)
val words = lines.flatMap (line => line.split (" "))
    // cada item do RDD é uma palavra do arquivo
val intermData = words.map (word => (word,1))
    // cada item do arquivo é um par (palavra,1)
```

WordCount em Spark

```
val lines = sc.textFile (inputFile)
    // cada item do RDD é uma linha do arquivo (String)
val words = lines.flatMap (line => line.split (" "))
    // cada item do RDD é uma palavra do arquivo
val intermData = words.map (word => (word,1))
    // cada item do arquivo é um par (palavra,1)
val wordCount = intermData.reduceByKey (_ + _)
    // cada item do RDD contém a ocorrência final de cada
    // palavra.
```

WordCount em Spark

```
val lines = sc.textFile (inputFile)
   // cada item do RDD é uma linha do arquivo (String)
val words = lines.flatMap (line => line.split (" "))
   // cada item do RDD é uma palavra do arquivo
val intermData = words.map (word => (word,1))
   // cada item do arquivo é um par (palavra,1)
val wordCount = intermData.reduceByKey (_ + _)
   // cada item do RDD contém a ocorrência final de cada
   // palavra.
val 5contagens = wordCount.take (5)
   // 5 resultados no programa driver
```

WordCount em Spark

```
val lines = sc.textFile (inputFile)
val words = lines.flatMap (line => line.split (" "))
val intermData = words.map (word => (word,1))
val wordCount = intermData.reduceByKey (_ + _)
val 5contagens = wordCount.take (5)
```

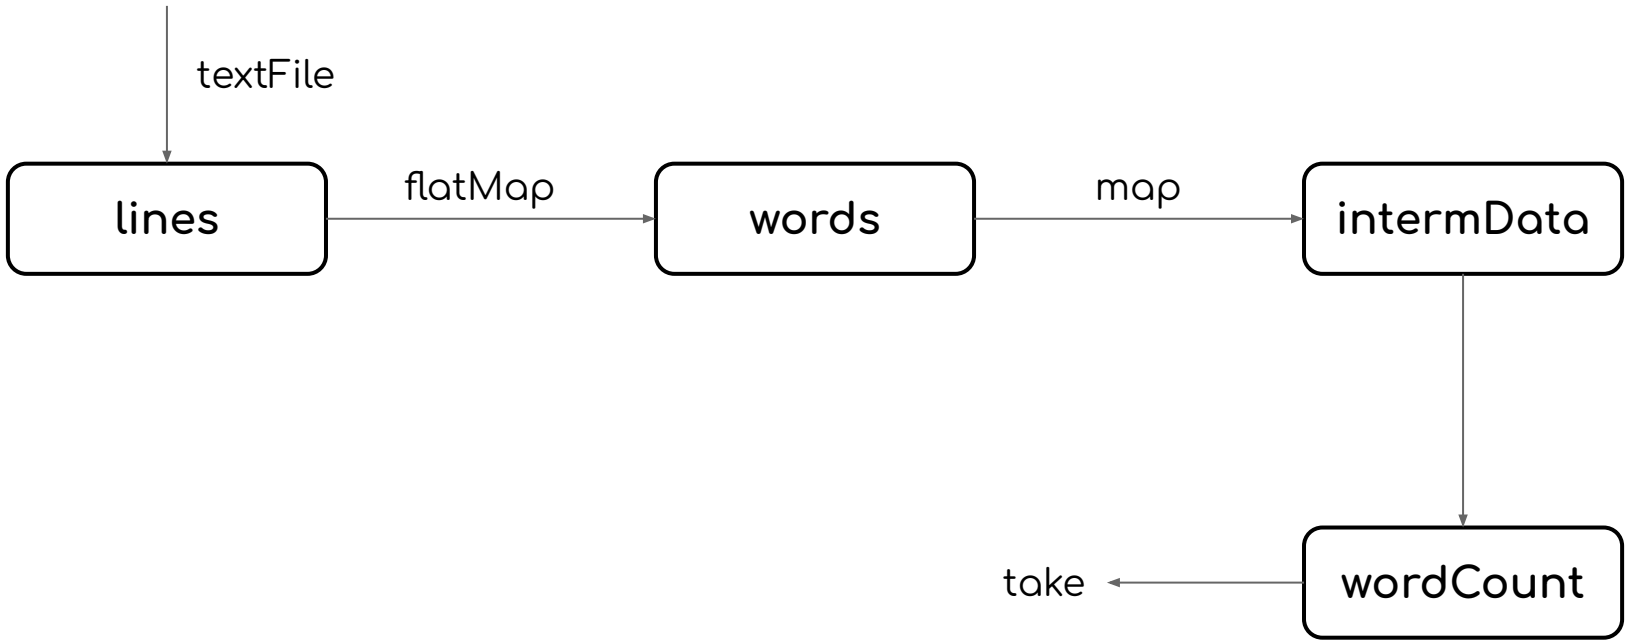

Spark application UI

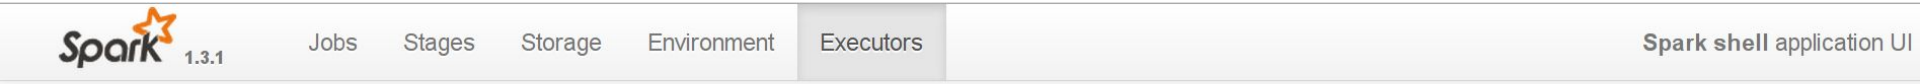

Executors (1)

Memory: 0.0 B Used (267.3 MB Total)
Disk: 0.0 B Used

Executor ID	Address	RDD Blocks	Memory Used	Disk Used	Active Tasks	Failed Tasks	Complete Tasks	Total Tasks	Task Time	Input	Shuffle Read	Shuffle Write	Thread Dump
<driver>	localhost:34847	0	0.0 B / 267.3 MB	0.0 B	0	0	0	0	0 ms	0.0 B	0.0 B	0.0 B	Thread Dump

Persistência

⇒ RDDs são avaliados preguiçosamente.
⇒ isso significa que haverá recomputação toda vez que uma ação sobre esse RDD for solicitada.
⇒ **Exemplo:** gerar um RDD de números aleatórios (pseudo).

```
val recompRDD = sc.parallelize (1 to 1000000).
   map (_ => Math.random())
for (i <- 1 to 10) println(recompRDD.reduce(_+_))
```

Persistência (localhost:4040)

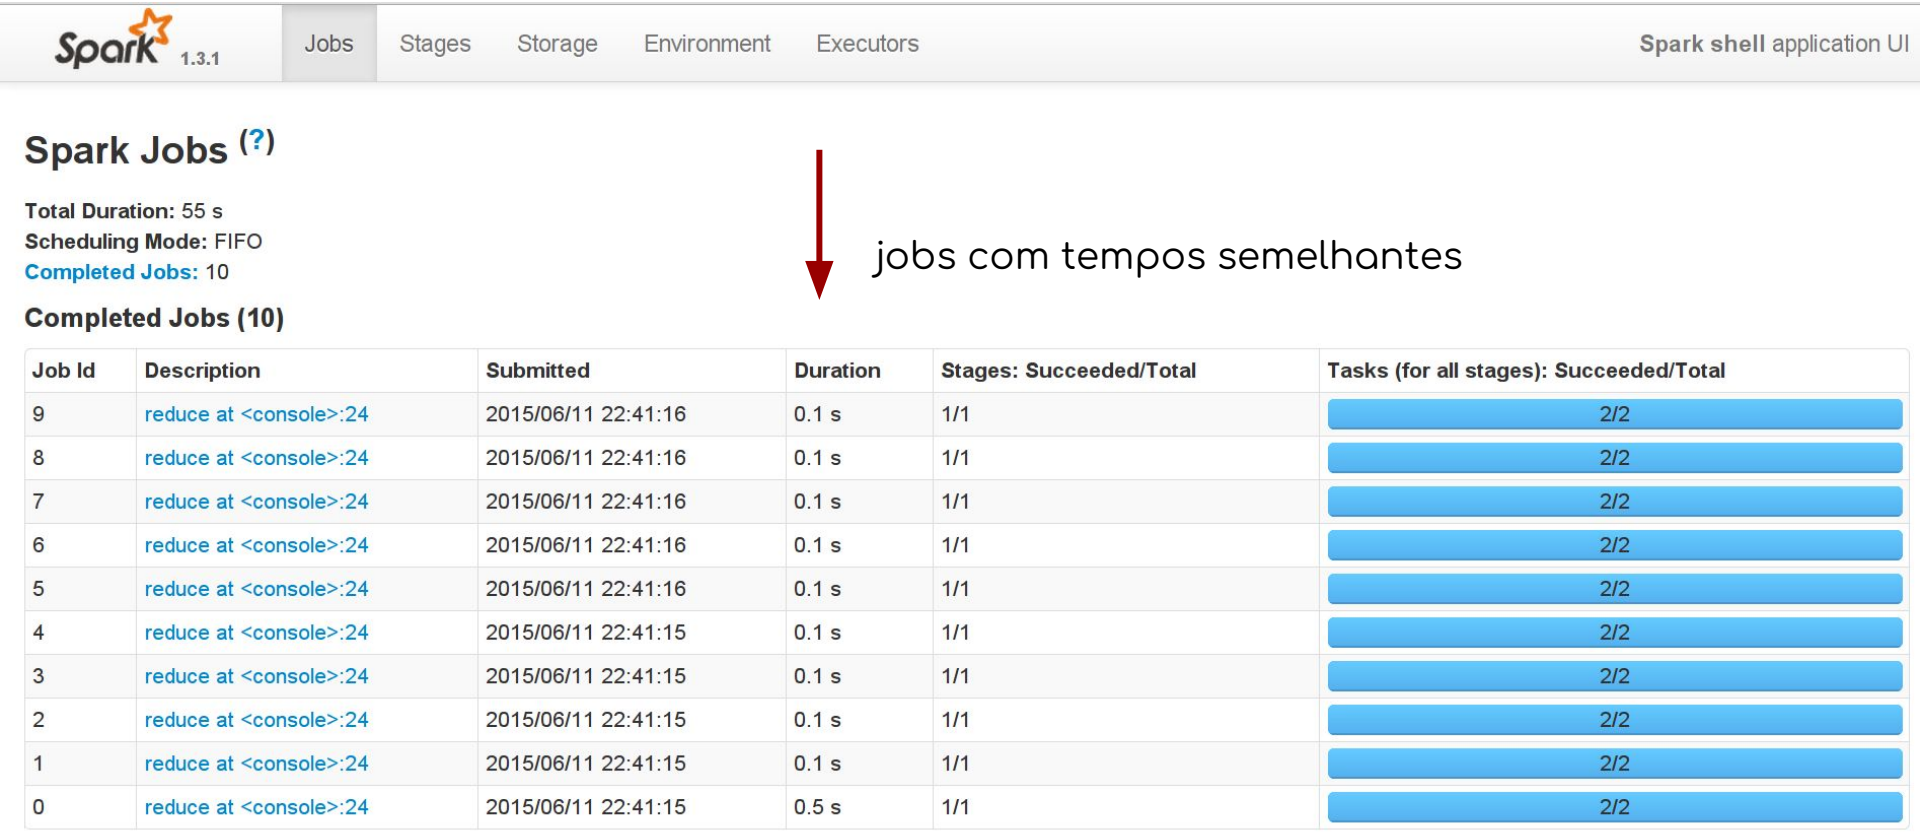

Job Id	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
9	reduce at <console>:24	2015/06/11 22:41:16	0.1 s	1/1	2/2
8	reduce at <console>:24	2015/06/11 22:41:16	0.1 s	1/1	2/2
7	reduce at <console>:24	2015/06/11 22:41:16	0.1 s	1/1	2/2
6	reduce at <console>:24	2015/06/11 22:41:16	0.1 s	1/1	2/2
5	reduce at <console>:24	2015/06/11 22:41:16	0.1 s	1/1	2/2
4	reduce at <console>:24	2015/06/11 22:41:15	0.1 s	1/1	2/2
3	reduce at <console>:24	2015/06/11 22:41:15	0.1 s	1/1	2/2
2	reduce at <console>:24	2015/06/11 22:41:15	0.1 s	1/1	2/2
1	reduce at <console>:24	2015/06/11 22:41:15	0.1 s	1/1	2/2
0	reduce at <console>:24	2015/06/11 22:41:15	0.5 s	1/1	2/2

API de persistência

```
val cachedRDD = anyRDD.persist (<nível>)
```

⇒ **<nível>** indica se o *caching* deve ser feito em memória, disco, serializado ou misturas.

```
val cachedRDD = anyRDD.cache()
```

⇒ **cache()** considera o nível padrão, isto é, MEMORY_ONLY.

⇒ o mesmo que `persist(StorageLevel.MEMORY_ONLY)`

Persistência (níveis)

nível	consumo espaço	consumo CPU	em memória	em disco
MEMORY_ONLY	muito	pouco	tudo	nada
MEMORY_ONLY_SER	pouco	muito	tudo	nada
MEMORY_AND_DISK	muito	médio	parte	parte
MEMORY_AND_DISK_SER	pouco	muito	parte	parte
DISK_ONLY	pouco	muito	nada	tudo

Persistência (depois)

⇒ RDDs são avaliados preguiçosamente.
⇒ isso significa que haverá recomputação toda vez que uma ação sobre esse RDD for solicitada.

```
val recompRDD = sc.parallelize (1 to 1000000).
   map (_ => Math.random()).cache()
for (i <- 1 to 10) println(recompRDD.reduce(_+_))
```

Persistência (localhost:4040)

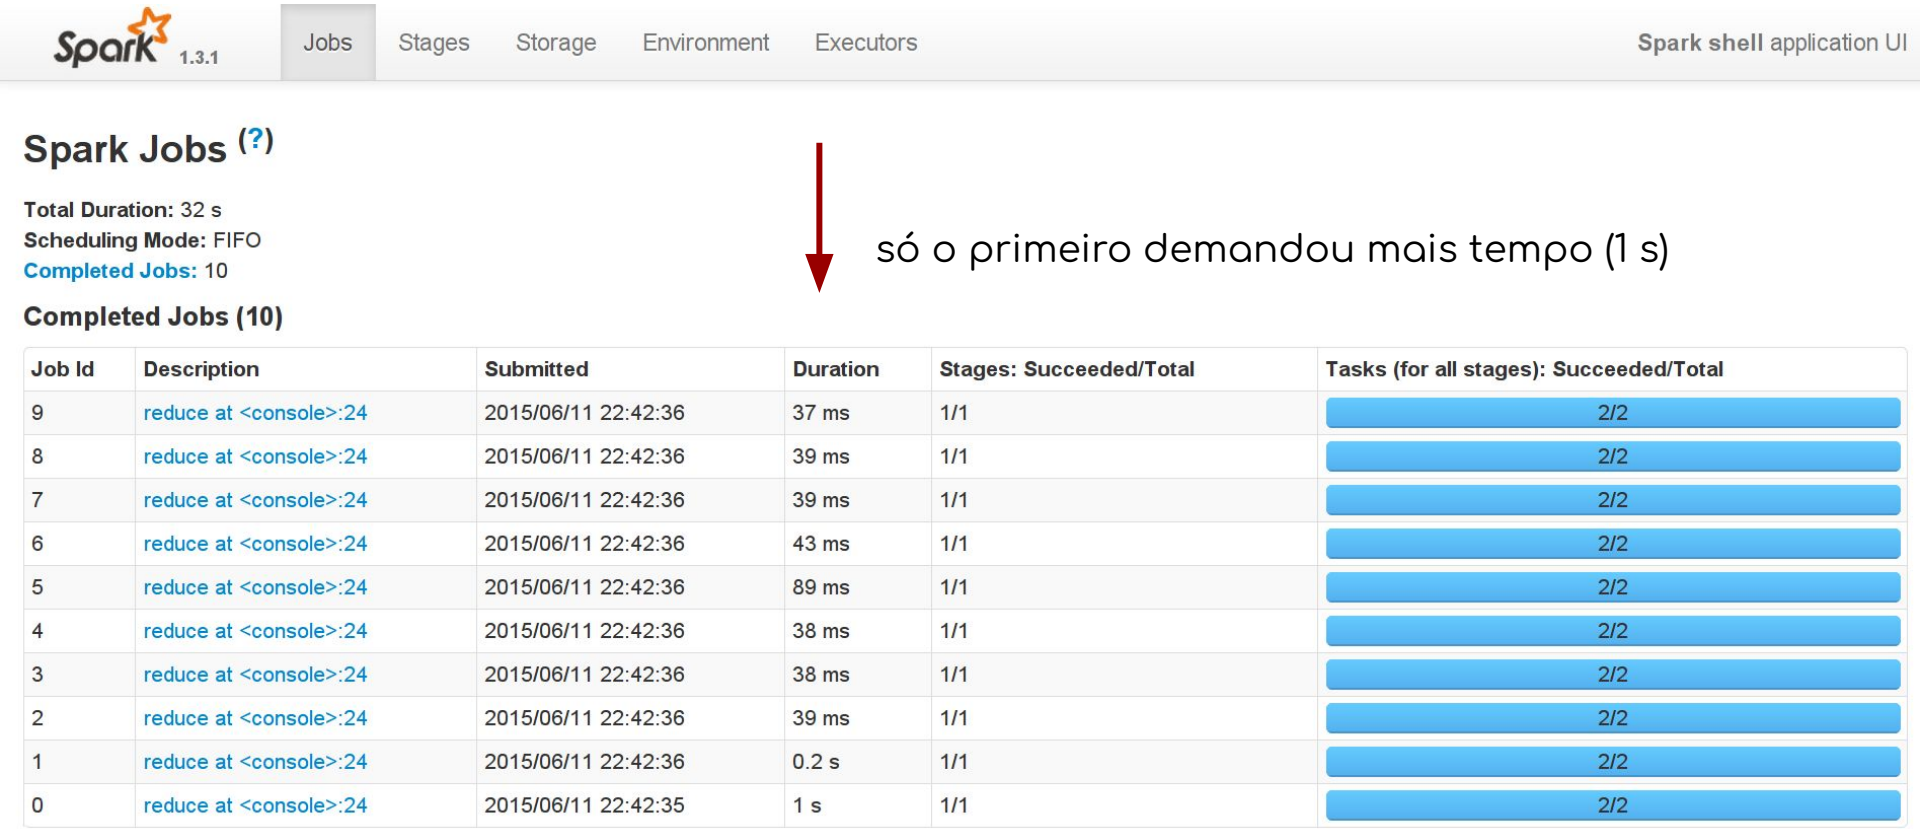

Job Id	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
9	reduce at <console>:24	2015/06/11 22:42:36	37 ms	1/1	2/2
8	reduce at <console>:24	2015/06/11 22:42:36	39 ms	1/1	2/2
7	reduce at <console>:24	2015/06/11 22:42:36	39 ms	1/1	2/2
6	reduce at <console>:24	2015/06/11 22:42:36	43 ms	1/1	2/2
5	reduce at <console>:24	2015/06/11 22:42:36	89 ms	1/1	2/2
4	reduce at <console>:24	2015/06/11 22:42:36	38 ms	1/1	2/2
3	reduce at <console>:24	2015/06/11 22:42:36	38 ms	1/1	2/2
2	reduce at <console>:24	2015/06/11 22:42:36	39 ms	1/1	2/2
1	reduce at <console>:24	2015/06/11 22:42:36	0.2 s	1/1	2/2
0	reduce at <console>:24	2015/06/11 22:42:35	1 s	1/1	2/2

Mais operações

transformações: `join`

⇒ `pairRdd.join(otherPairRdd)`:
faz um *inner-join* entre os dois RDDs.

- esta operação combina itens de dois RDDs de pares pela chave.
  - ➢ o resultado é um RDD contendo todas as combinações de pares de valores que compartilham uma mesma chave nos RDDs de entrada.

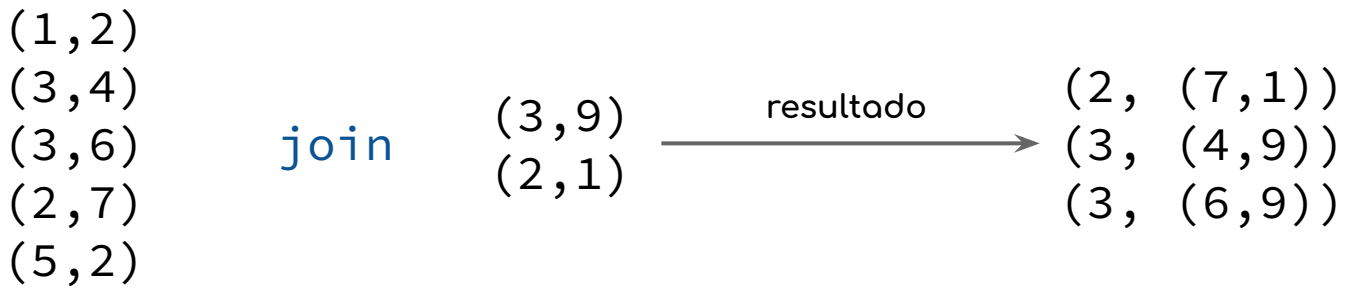

Estudo de caso: *pagerank*

⇒ É um exemplo clássico que mostra dois pontos fortes de Spark: *caching* e *computação iterativa*.

⇒ **Propósito:** criar um ranqueamento de importância de nós em um grafo.

⇒ Onde é usado?
- o **Google search** utiliza o PageRank.
- ele foi proposto por Larry Page, cofundador da Google.

⇒ Sabe a ordem de links que aparecem em uma busca que você faz no Google search?
- sim, o PageRank que foi usado para ranqueá-los.

Premissa do *PageRank*

A importância de uma página é determinada pela importância das páginas que apontam para ela.

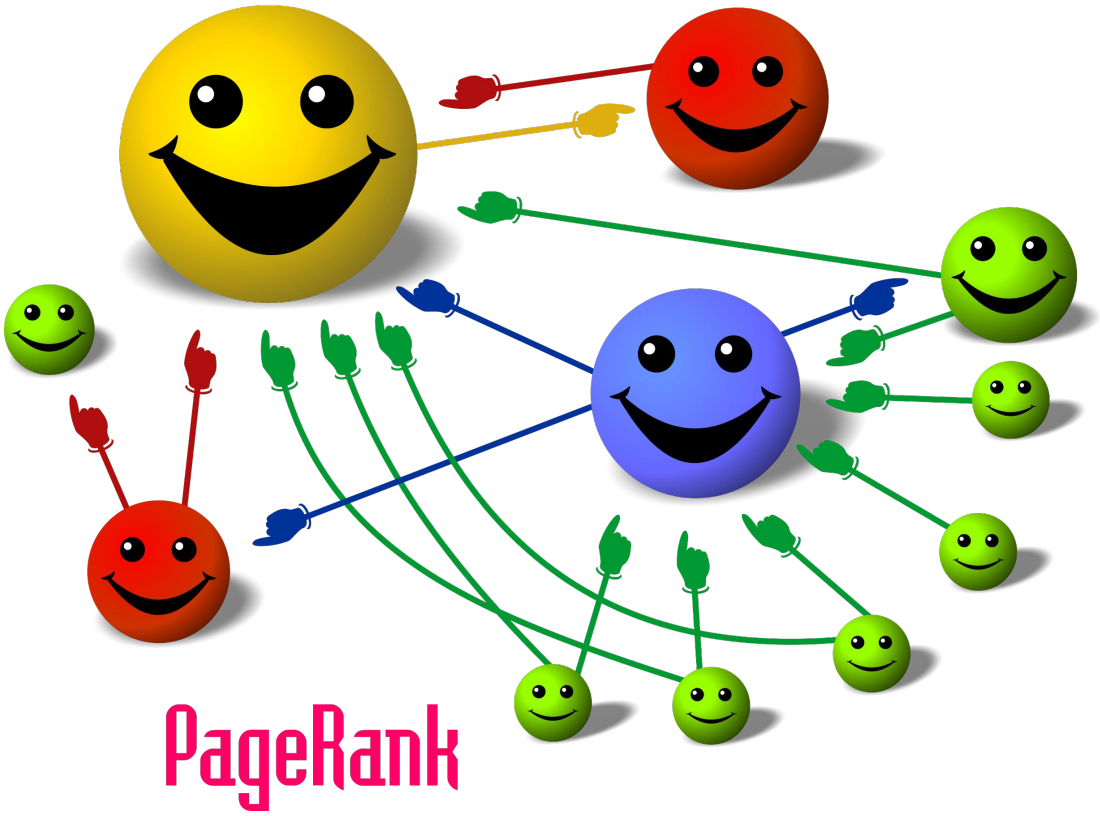

Descrição do algoritmo (parte 1)

⇒ Temos uma estrutura representando páginas e para quem elas apontam.

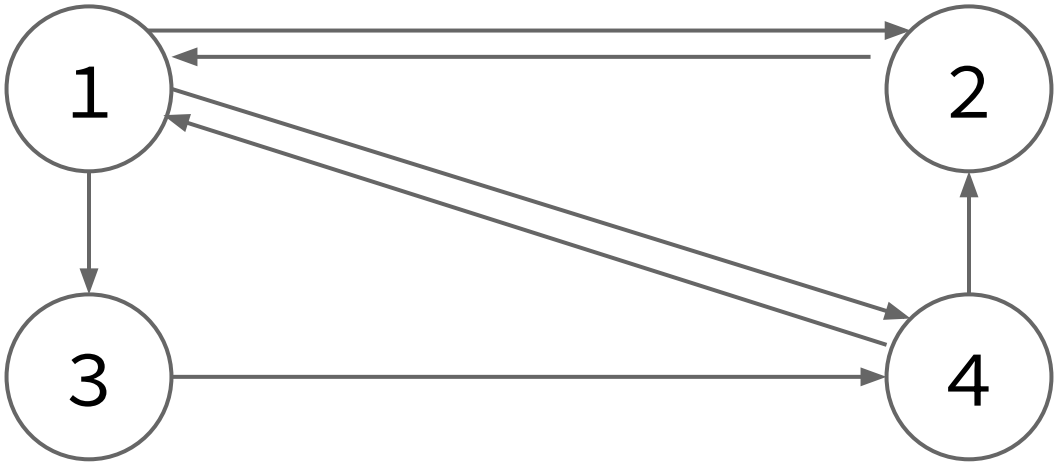

Os números poderiam representar (hipoteticamente):

1. portal.dataprev.gov.br
2. dcc.ufmg.br
3. spark.apache.org
4. vagrantup.com

Descrição do algoritmo (parte 2)

⇒ Todas iniciam com importância 1.0, ou seja, 100%.

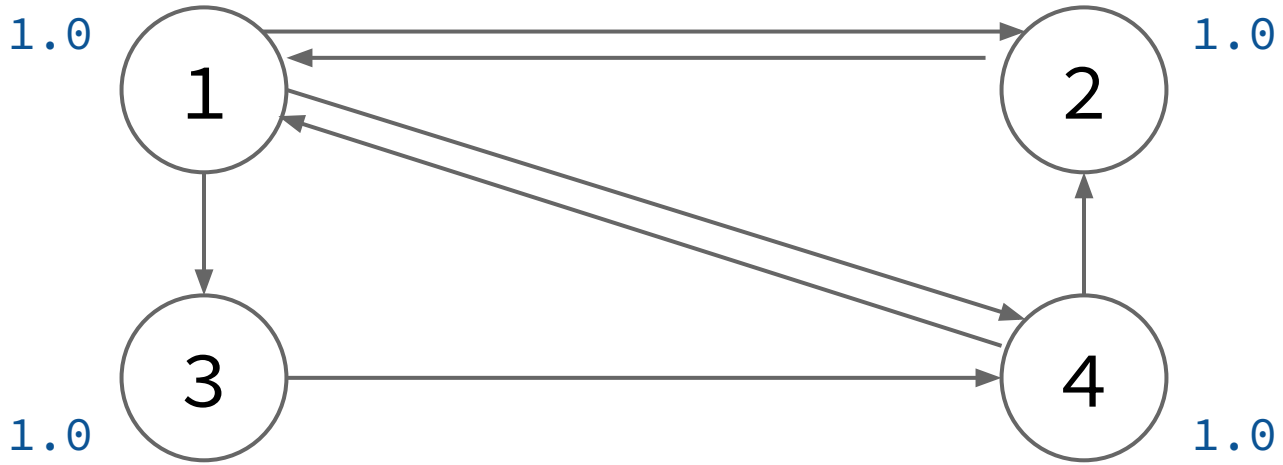

Descrição do algoritmo (parte 3)

⇒ A cada iteração toda página distribui sua importância igualmente para os vizinhos.

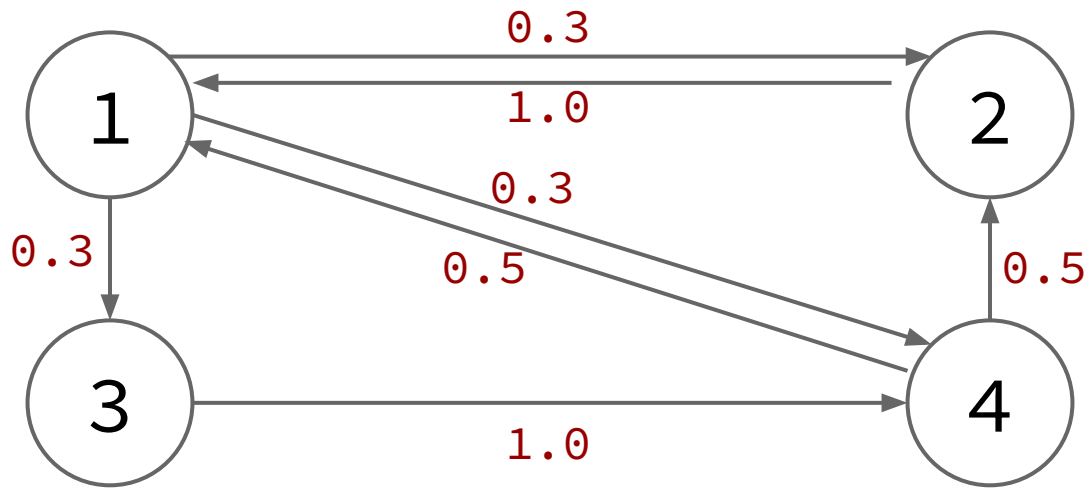

Descrição do algoritmo (parte 4)

⇒ Agora cada página tem uma nova importância, que é a soma dos valores recebidos.

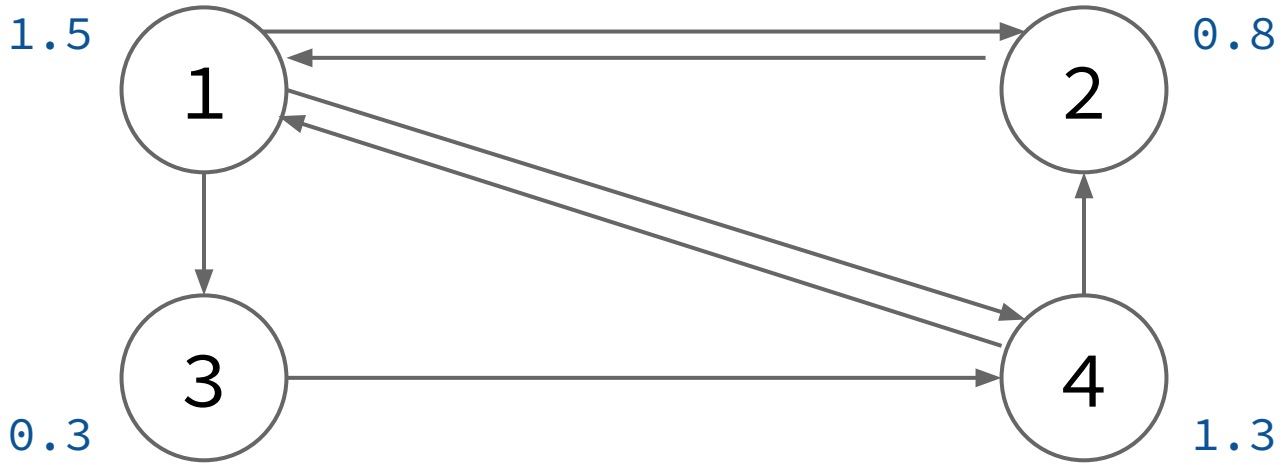

⇒ O processo se repete, por um número determinado de iterações.

⇒ **Páginas com números maiores são mais importantes**.

PageRank: implementação

```
object PageRank {
    def main(args: Array[String]) {
        val links = // RDD de pares (página, lista de adjacência)
        links.cache()
        var rankings = // RDD de pares (página, 1.0)

        for (i <- 1 to ITERATIONS) {
            val contribs = links.join(rankings).flatMap {
                case (url, (adjList, rank)) =>
                    adjList.map(dest => (dest, rank / adjList.size))
            }
            rankings = contribs.reduceByKey (_ + _)
        }
    }
}
```

⇒ Parte iterativa.

- é o laço principal, que ocorre no driver.

⇒ Parte paralela.

- são as transformações a cada iteração.

PageRank: submissão

```
$ ./spark/bin/spark-submit \
    --class my.spark.app.PageRank \
    --master local[*] \
    my-spark-app/app/build/libs/app.jar \
    data/twitch-edges.txt 3
```

Próximos passos ...

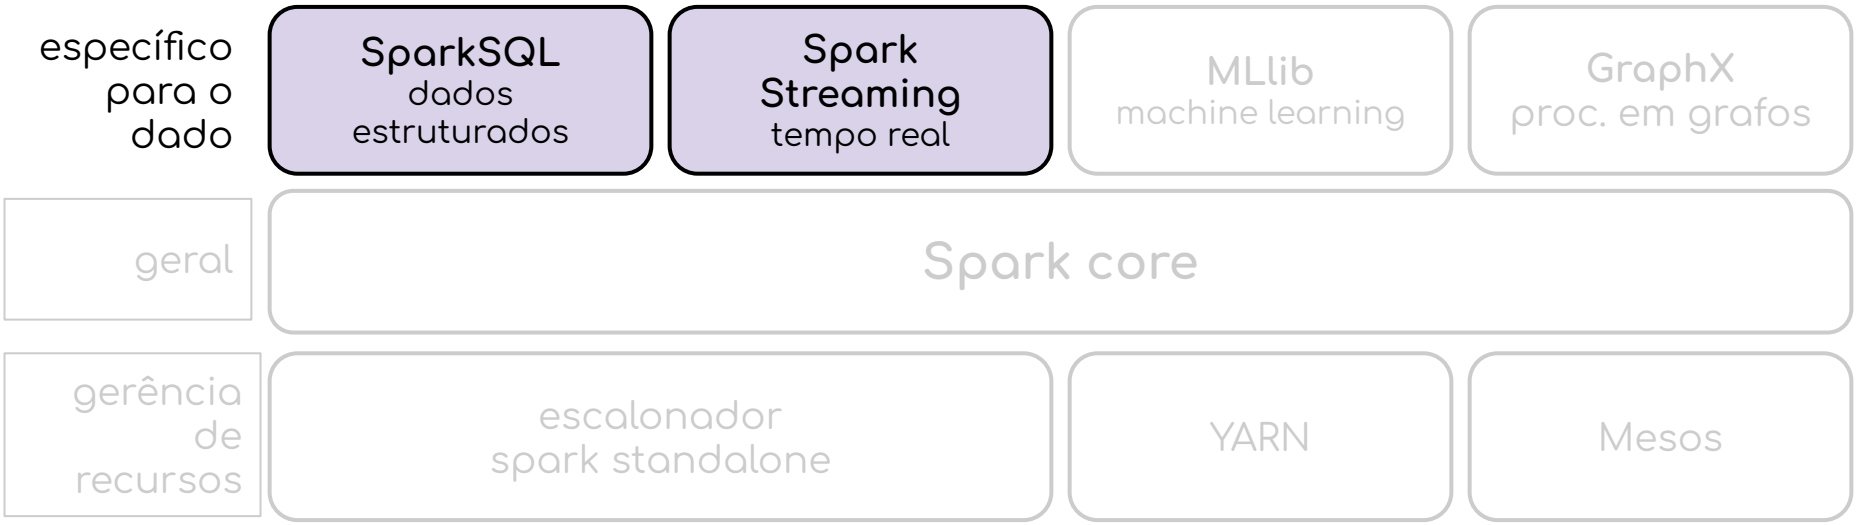

Referências

⇒ Resilient distributed datasets: a fault-tolerant abstraction for in-memory cluster computing. (Zaharia M. et al.)

⇒ Learning Spark. (Karau H.; Konwinski A.; Wendell P.; Zaharia M.)

⇒ Spark Docs. (versão mais recente)

⇒ Advanced Spark Features. (Spark Summit 2012)

⇒ Advanced Spark. (Databricks 2014)

⇒ Spark API. (classe RDD como ponto de partida)

⇒ Spark By Examples (exemplos práticos de configuração e uso da ferramenta)